

# De la tasa esperada a las elipses

Qué estima la CRB, cómo se construye la covarianza  
y por qué las burbujas tienen esa forma

Repositorio `crb`

4 de septiembre de 2026

## Resumen

Este texto cubre **solo** la mitad estadística del *pipeline*: a partir del momento en que el simulador ya ha producido la tasa esperada de fotones  $g(\psi)$ . No se rederiva la radiometría ni el rasterizado. La pregunta que queda es: si un SPAD observara esa tasa con ruido de Poisson, **cuánto podríamos saber de la pose**  $\psi = (\rho, \varphi)$ . La respuesta no se obtiene simulando estimadores: se obtiene de la matriz de información de Fisher y de su inversa, la cota de Cramér–Rao (CRB), que es una covarianza. De esa covarianza se lee  $\sigma_\rho$ ,  $\sigma_\varphi$ , la correlación, y se dibuja una elipse de radio  $k$  en el plano de parámetros. Cada fórmula se justifica y se ata al código de `crb_polar_functions.py`.

## Índice

|                                                        |    |
|--------------------------------------------------------|----|
| 1. Qué problema se resuelve (y qué no)                 | 2  |
| 2. El objeto de partida: la tasa $g(\psi)$             | 2  |
| 3. Qué significaría estimar                            | 3  |
| 4. De la <i>score</i> a Fisher                         | 4  |
| 4.1. Cómo leer cada término . . . . .                  | 4  |
| 5. El jacobiano: de $g$ a $J$ por diferencias finitas  | 4  |
| 6. La cota: Fisher invertida es una covarianza         | 5  |
| 6.1. El enunciado . . . . .                            | 5  |
| 6.2. Qué es y qué no es $\mathbf{C}$ . . . . .         | 5  |
| 6.3. La correlación . . . . .                          | 6  |
| 7. De la matriz a la elipse                            | 6  |
| 7.1. La región de Mahalanobis . . . . .                | 6  |
| 7.2. Por qué $k = 3$ (y qué cambia $k = 1$ ) . . . . . | 6  |
| 7.3. La inclinación es la correlación . . . . .        | 7  |
| 8. Cómo se dibuja (y por qué se ve arqueada)           | 8  |
| 9. Cómo leer una burbuja                               | 10 |
| 10. Mapa al código                                     | 10 |

---

## 1. Qué problema se resuelve (y qué no)

Tenemos un modelo  $g(\psi)$ : un cubo (píxel, *bin*) de tasas esperadas de fotones, función de la pose de la faceta. Lo que *no* tenemos —y el CRB no necesita— es una medición ruidosa concreta. El objeto que se calcula es una **cota** sobre cualquier estimador razonable de esa pose.

El vector de parámetros en el *baseline* actual es

$$\psi = \begin{pmatrix} \rho \\ \varphi \end{pmatrix} \in \mathbb{R}_{>0}^2 \times (0, \pi). \quad (1)$$


$\rho$  es la distancia al origen en el suelo y  $\varphi$  el azimut. El ancho de la faceta  $w$  es un dato de escena, no se estima. La altura no entra: el simulador de producción no la expone como entrada, así que no existe  $\partial g / \partial h$  y la Fisher es  $2 \times 2$ .

Un **estimador** sería una función  $\hat{\psi}(\mathbf{x})$  que, dada una realización ruidosa  $\mathbf{x}$  del transitorio, devolviera un par  $(\hat{\rho}, \hat{\varphi})$ . El de máxima verosimilitud, por ejemplo, maximiza  $\ell(\psi; \mathbf{x})$  de la sección ?? **Ese paso no se ejecuta**. No hay bucle de optimización, no hay semilla, no hay promedio Monte Carlo. Lo que se calcula es: si existiera un estimador insesgado, su covarianza no podría ser mejor que  $\mathbf{I}(\psi)^{-1}$ . Dibujar esa matriz como elipse es dibujar **el mejor error típico posible** bajo el modelo, no el error de un algoritmo concreto.

**Observación 1** (El CRB no consume datos). El *pipeline* llama al *forward* con `add_noise=False` (`force_no_noise=True` en `compute_crb_polar`). El «ruido» entra solo por la forma analítica de la verosimilitud de Poisson: la varianza de cada conteo *es* su media. El cálculo es determinista.

La cadena, implementada de punta a punta en `compute_crb_polar`, es esta:

Cadena que implementa `compute_crb_polar` (sin mediciones ruidosas)



## 2. El objeto de partida: la tasa $g(\psi)$

Sea  $y(\psi)$  el transitorio esperado que sale del simulador (sin ruido). Cada índice  $q$  enumera un par (píxel, *bin*). Con la grilla *baseline* de  $32 \times 32$  píxeles y 95 *bins* hay  $N = 97\,280$  índices. Se añade un fondo constante

$$g_q(\psi) = y_q(\psi) + b, \quad b = 0,1 \text{ cuentas/bin}, \quad (2)$$

que en el código es `forward_g_polar`:

```
background = background_rate * ones_like(y_signal)
return y_signal + background
```

El valor  $b = 0,1$  es `BASELINE_BACKGROUND_RATE`.

Dos razones, una física y una matemática:

- Un SPAD real tiene cuentas oscuras y luz ambiente; ningún *bin* tiene tasa exactamente cero.
- Sin  $b$ , los miles de *bins* vacíos tendrían  $g_q = 0$  y el peso  $1/g_q$  de la Fisher divergiría. Con  $b = 0,1$  el piso numérico `fisher_eps` =  $10^{-12}$  de `fisher_poisson` no llega a actuar.

El modelo de medición, a partir de aquí, es

$$X_q \sim \text{Poisson}(g_q(\boldsymbol{\psi})) \quad \text{independientes dado } \boldsymbol{\psi}. \quad (3)$$

La propiedad que hace trabajar a todo lo que sigue es

$$\text{Var}(X_q) = \mathbb{E}[X_q] = g_q(\boldsymbol{\psi}). \quad (4)$$

No hay un parámetro de ruido libre: el nivel de señal fija la incertidumbre. Por eso las constantes radiométricas del *forward* (intensidad del láser, fondo, número de píxeles) *sí* cambian el CRB: no se cancelan al «normalizar».

**Salvedad 1** (Independencia). Distintos *bins* temporales son ventanas disjuntas y distintos píxeles son detectores separados, así que (3) es razonable para un contador ideal. Ignora tiempo muerto, diafonía y *jitter*. El CRB que sale es por tanto el de un detector ideal: optimista frente a un sensor real.

### 3. Qué significaría estimar

Dada una realización  $\mathbf{x}$ , la log-verosimilitud de Poisson es

$$\ell(\boldsymbol{\psi}; \mathbf{x}) = \sum_{q=1}^N [x_q \ln g_q(\boldsymbol{\psi}) - g_q(\boldsymbol{\psi}) - \ln(x_q!)]. \quad (5)$$

El factorial no depende de  $\boldsymbol{\psi}$ . El estimador de máxima verosimilitud (MV) sería

$$\hat{\boldsymbol{\psi}}_{\text{MV}}(\mathbf{x}) = \arg \max_{\boldsymbol{\psi}} \ell(\boldsymbol{\psi}; \mathbf{x}). \quad (6)$$

Intuitivamente: se busca la pose cuya tasa esperada  $g(\boldsymbol{\psi})$  hace más probable el histograma observado. En un modelo regular, el MV es asintóticamente insesgado, gaussiano y **alcanza** la CRB cuando  $N$  es grande. Eso justifica leer  $\mathbf{I}^{-1}$  no solo como «nadie puede hacerlo mejor», sino como «el MV, si se corriera, se parecería a esto».

Tres precisiones evitan sobreinterpretarlo:

- Aquí **no se corre** (6). No hay garantía numérica de que un optimizador sobre este *forward* (que es escalonado) alcance la cota.
- La cota vale para estimadores **insesgados**. Un estimador sesgado puede tener varianza menor (el extremo,  $\hat{\boldsymbol{\psi}}$  constante, tiene varianza cero) a costa del sesgo.
- Es **local**:  $\mathbf{I}$  se evalúa en un  $\boldsymbol{\psi}_0$  concreto y describe la curvatura de  $\ell$  ahí. No detecta ambigüedades globales (dos poses lejanas con transitorios parecidos).

La *score* —el gradiente de  $\ell$ — es lo que conecta estimar con Fisher. Derivando (5) respecto de la componente  $m$ ,

$$\frac{\partial \ell}{\partial \psi_m} = \sum_q \frac{x_q - g_q}{g_q} \frac{\partial g_q}{\partial \psi_m}. \quad (7)$$

Su esperanza es cero porque  $\mathbb{E}[x_q] = g_q$ : en media, la pendiente de  $\ell$  en el valor verdadero es nula, que es la condición de regularidad que usa la CRB. La información de Fisher es, por definición, la covarianza de esa pendiente:

$$I_{mk}(\boldsymbol{\psi}) = \mathbb{E} \left[ \frac{\partial \ell}{\partial \psi_m} \frac{\partial \ell}{\partial \psi_k} \right]. \quad (8)$$

Un modelo «informativo» es uno cuya log-verosimilitud cambia de pendiente de forma violenta cuando se mueve  $\boldsymbol{\psi}$ : la *score* tiene poca varianza alrededor de cero. Eso es exactamente lo que mide  $\mathbf{I}$ .

## 4. De la *score* a Fisher

Sustituyendo (7) en (8),

$$I_{mk} = \sum_q \sum_{q'} \frac{\mathbb{E}[(x_q - g_q)(x_{q'} - g_{q'})]}{g_q g_{q'}} \frac{\partial g_q}{\partial \psi_m} \frac{\partial g_{q'}}{\partial \psi_k}. \quad (9)$$

Aquí entra la independencia. Si  $q \neq q'$ ,  $\mathbb{E}[(x_q - g_q)(x_{q'} - g_{q'})] = 0$  y el término cruzado desaparece. Si  $q = q'$ , la esperanza es la varianza, que por (4) vale  $g_q$ . Queda

$$I_{mk}(\psi) = \sum_{q=1}^N \frac{1}{g_q(\psi)} \frac{\partial g_q}{\partial \psi_m} \frac{\partial g_q}{\partial \psi_k} \quad (10)$$

o, con el jacobiano  $\mathbf{J} \in \mathbb{R}^{N \times 2}$ ,  $\mathbf{J}_{qm} = \partial g_q / \partial \psi_m$ ,

$$\mathbf{I} = \mathbf{J}^T \text{diag}(1/g) \mathbf{J}. \quad (11)$$

Esto es literalmente `fisher_poisson`:

```
g_safe = np.maximum(g, eps); return J.T @ ((1.0/g_safe)[: , None] * J).
```

### 4.1. Cómo leer cada término

La contribución del índice  $q$  a  $I_{mm}$  es  $(\partial g_q / \partial \psi_m)^2 / g_q$ : sensibilidad al cuadrado sobre varianza. Un *bin* informa sobre  $\rho$  si (i) su tasa *cambia* al mover  $\rho$  y (ii) esa tasa no está ahogada por su propio ruido de Poisson. Los dos extremos aclaran la intuición:

- señal enorme pero insensible a la pose: numerador nulo, no aporta;
- muy sensible pero  $g_q$  casi nulo: el denominador amplifica, y por eso los *bins* del *borde* del pulso (derivada alta,  $g$  bajo) son los más informativos.

El fondo  $b$  **no añade** información. Los índices con  $\partial g_q / \partial \psi = 0$  contribuyen cero por muy grande que sea  $1/g_q$ . Lo que hace  $b$  es diluir los *bins* que sí tienen señal: sube su varianza sin subir su sensibilidad. Subir  $b$  empeora el CRB.

Dos propiedades estructurales:

- $\mathbf{I}$  es una **suma sobre mediciones**. Más píxeles o más *bins* informativos añaden términos. Eso es lo que hace que, en *este* modelo (que muestrea radiancia en el centro del píxel, sin factor de área),  $\sigma$  escale como  $1/N$  al refinar una grilla  $N \times N$ .
- $\mathbf{I}$  es simétrica y semidefinida positiva por construcción ( $\mathbf{B}^T \mathbf{B}$  con  $\mathbf{B} = \text{diag}(1/\sqrt{g}) \mathbf{J}$ ). Sus autovalores son  $\geq 0$  y la elipse de la sección 7 está bien definida.

## 5. El jacobiano: de $g$ a $J$ por diferencias finitas

(10) necesita  $\partial g / \partial \psi$ . El *forward* contiene un  $[\cdot]$  (asignación de *bin*), un indicador de oclusión y cuatro  $\max(0, \cdot)$  en los cosenos: no hay derivada clásica en todos los puntos. El *pipeline* la aproxima por diferencias centrales,

$$\mathbf{J}_{:,m} \approx \frac{g(\psi + \delta_m \mathbf{e}_m) - g(\psi - \delta_m \mathbf{e}_m)}{2 \delta_m}, \quad \boldsymbol{\delta} = (\delta_\rho, \delta_\varphi) = (0,01 \text{ m}, 0,5^\circ), \quad (12)$$

en `finite_difference_jacobian_polar`. Cada pose cuesta  $1 + 2 \cdot 2 = 5$  evaluaciones: una central para  $g(\psi_0)$  y cuatro perturbadas.

**Por qué centrales.** Si  $g$  fuera suave,  $[g(\psi + \delta) - g(\psi - \delta)]/(2\delta) = g'(\psi) + O(\delta^2)$ : los términos pares se cancelan. Una diferencia unilateral sería  $O(\delta)$ . El *forward* es caro pero no prohibitivo; pagar una evaluación extra por columna a cambio de un orden de precisión es la elección correcta.

**El problema honesto.**  $g$  no es suave. Para un triángulo aislado, mover  $\rho$  en 1 cm casi nunca cruza un borde de *bin* ( $c\Delta t \approx 11,7$  cm de camino), y la derivada estimada sale 0; cuando sí lo cruza, salta una masa entera. Lo que rescata el cálculo es la suma sobre 32 768 triángulos: cada uno tiene su propio umbral, al mover  $\rho$  una fracción proporcional a  $\delta_\rho$  cruza, y el agregado se comporta como una rampa. La suma sobre los 97 280 índices de (10) cancela además residuos de signo distinto. El resultado práctico, medido en  $(1 \text{ m}, 90^\circ)$ , es que  $\sigma_\varphi$  casi no se mueve al variar  $\delta_\rho$  en un factor 40, y  $\sigma_\rho$  crece de forma monótona y suave ( $\sim 3\%$  entre el paso de 10 mm y el extrapolado a paso cero). No demuestra diferenciabilidad; demuestra que el promediado basta para que la cota no dependa de una elección arbitraria del paso.

El *baseline* usa `float64` precisamente porque el numerador de (12) resta dos números parecidos. En `float32` esa cancelación dejaría pocos dígitos; elevados al cuadrado en **I** serían ruido.

## 6. La cota: Fisher invertida es una covarianza

### 6.1. El enunciado

Para cualquier estimador  $\hat{\psi}(\mathbf{x})$  insesgado de  $\psi$ ,

$$\text{Cov}(\hat{\psi}) \succeq \mathbf{I}(\psi)^{-1}, \quad (13)$$

en el sentido de matrices:  $\text{Cov} - \mathbf{I}^{-1}$  es semidefinida positiva. En particular, tomando diagonales,  $\text{Var}(\hat{\rho}) \geq [\mathbf{I}^{-1}]_{11}$  y  $\text{Var}(\hat{\varphi}) \geq [\mathbf{I}^{-1}]_{22}$ . El código define

$$\mathbf{C} = \mathbf{I}^+, \quad \sigma_\rho = \sqrt{C_{11}}, \quad \sigma_\varphi = \sqrt{C_{22}}, \quad \sigma_{\text{tang}} = \rho \sigma_\varphi, \quad (14)$$

en `_crb_sigmas_from_matrix`.  $\sigma_{\text{tang}}$  pasa  $\sigma_\varphi$  (radianes) a metros de arco en la pose nominal, para compararlo con  $\sigma_\rho$  en las mismas unidades.

Se usa `np.linalg.pinv` y no `inv`. Si en alguna pose una dirección de  $\psi$  no fuera observable, **I** sería singular e `inv` abortaría la rejilla. La pseudoinversa anula esa dirección y deja que las  $\sigma$  delaten el problema. En las 15 poses del *baseline* **I** está bien condicionada y ambas coinciden.

### 6.2. Qué es y qué no es C

**C** es la **covarianza mínima** de  $(\hat{\rho}, \hat{\varphi})$ , no un histograma de errores medidos. Sus unidades son

$$C_{11} \text{ en m}^2, \quad C_{22} \text{ en rad}^2, \quad C_{12} \text{ en m} \cdot \text{rad}.$$

Los  $\sigma$  de (14) son las incertidumbres **conjuntas**: las de estimar  $\rho$  y  $\varphi$  a la vez. La incertidumbre condicional (si  $\varphi$  se conociera de antemano) sería  $1/\sqrt{I_{\rho\rho}}$ , siempre menor o igual:

$$\sigma_\rho = \frac{1}{\sqrt{I_{\rho\rho}}} \cdot \frac{1}{\sqrt{1 - r_I^2}}, \quad r_I = \frac{I_{\rho\varphi}}{\sqrt{I_{\rho\rho}I_{\varphi\varphi}}}. \quad (15)$$

Estimar un parámetro extra nunca sale gratis: la correlación infla las  $\sigma$  marginales. Ese es el mismo mecanismo por el que, cuando el CRB tenía tres parámetros  $(\rho, \varphi, h)$ , añadir la altura ensanchaba las burbujas en  $(\rho, \varphi)$ .

### 6.3. La correlación

El término fuera de la diagonal se reporta como

$$r_{\rho\varphi} = \frac{C_{12}}{\sqrt{C_{11}C_{22}}}. \quad (16)$$

$I_{\rho\varphi} = \sum_q g_q^{-1}(\partial_\rho g_q)(\partial_\varphi g_q)$  se anularía solo si ninguna medición fuera sensible a ambos parámetros a la vez. Aquí ocurre lo contrario: el camino  $d_1 + d_2$  depende de  $(\rho \cos \varphi, \rho \sin \varphi)$ , y la frontera de occlusión también. Mover  $\rho$  desplaza la sombra, que es precisamente el mecanismo que informa sobre  $\varphi$ .

En toda la rejilla *baseline*  $r_{\rho\varphi} < 0$ : una sobreestimación de  $\rho$  tiende a ir con una subestimación de  $\varphi$ . Existe una **dirección de compensación** a lo largo de la cual el transitorio cambia poco (alejar la faceta y girarla hacia el hueco produce, al primer orden, un camino y una sombra parecidos). El estimador distingue bien el desplazamiento perpendicular a esa dirección y mal el paralelo. Eso es la elipse alargada e inclinada.

**Observación 2** (Coordenadas independientes, estimadores correlacionados).  $\rho$  y  $\varphi$  se pueden fijar por separado: nada las liga *a priori*. Lo correlacionado son los **errores de sus estimaciones**, porque los datos no las separan limpiamente. Son afirmaciones sobre objetos distintos.

## 7. De la matriz a la elipse

### 7.1. La región de Mahalanobis

Una covarianza  $2 \times 2$  definida positiva define una familia de elipses. Para un error  $\delta = \psi - \psi_0$ ,

$$\mathcal{E}_k = \{ \delta \in \mathbb{R}^2 : \delta^\top \mathbf{C}^{-1} \delta \leq k^2 \} \quad (17)$$

es el conjunto de desplazamientos cuya distancia de Mahalanobis a  $\psi_0$  es a lo sumo  $k$ . La forma cuadrática  $\delta^\top \mathbf{C}^{-1} \delta$  vale 1 sobre la elipse de covarianza «unidad» y  $k^2$  sobre la de radio  $k$ : **el número  $k$  no cambia la forma, solo la escala.**

Como  $\mathbf{C}$  es simétrica definida positiva existe

$$\mathbf{C} = \mathbf{V} \mathbf{\Lambda} \mathbf{V}^\top, \quad \mathbf{\Lambda} = \text{diag}(\lambda_1, \lambda_2), \quad \mathbf{V} \text{ ortogonal.} \quad (18)$$

El cambio  $\delta = \mathbf{V} \mathbf{\Lambda}^{1/2} \mathbf{u}$  convierte (17) en  $\|\mathbf{u}\| \leq k$ . La frontera es por tanto la imagen de un círculo de radio  $k$ :

$$\delta(\vartheta) = k \mathbf{V} \mathbf{\Lambda}^{1/2} \begin{pmatrix} \cos \vartheta \\ \sin \vartheta \end{pmatrix}, \quad \vartheta \in [0, 2\pi). \quad (19)$$

Semiejes  $k\sqrt{\lambda_i}$ , orientados según los autovectores de  $\mathbf{C}$ . Eso es exactamente la función `crb_region_in_polar_parameters`:

```
evals, evecs = np.linalg.eigh(Sigma)
axes = k * np.sqrt(evals)
ellipse = center[:,None] + evecs @ np.diag(axes) @ circle
```

con el círculo unidad muestreado en 300 puntos y `np.maximum(eigenvalues, 0)` como guarda contra autovalores ligeramente negativos por redondeo. El bloque  $\Sigma$  es  $\mathbf{C}[\{0, 1\}, \{0, 1\}]$ ; con Fisher  $2 \times 2$  es  $\mathbf{C}$  entero.

### 7.2. Por qué $k = 3$ (y qué cambia $k = 1$ )

Si los errores fueran gaussianos de covarianza  $\mathbf{C}$ , la forma cuadrática  $\delta^\top \mathbf{C}^{-1} \delta$  seguiría una  $\chi^2$  con 2 grados de libertad, cuya función de distribución es  $F(u) = 1 - e^{-u/2}$ . Entonces

$$\Pr(\delta \in \mathcal{E}_k) = 1 - e^{-k^2/2}. \quad (20)$$

## De la esfera de Mahalanobis a la elipse de covarianza




Figura 1: Izquierda: el círculo  $\|\mathbf{u}\| = 1$  en las coordenadas blanqueadas. Derecha: su imagen bajo  $\mathbf{V}\mathbf{\Lambda}^{1/2}$ , que es la elipse  $1\sigma$  en  $(\delta\rho, \delta\varphi)$ . Los ejes de color son  $k\sqrt{\lambda_i}$  con  $k = 1$ . Pose (1 m,  $90^\circ$ ), CRB *baseline*  $32 \times 32$ .

| $k$ | cobertura 2D (20)        | tamaño lineal vs $1\sigma$ | área vs $1\sigma$ |
|-----|--------------------------|----------------------------|-------------------|
| 1   | $1 - e^{-1/2} = 39,3 \%$ | 1                          | 1                 |
| 2   | $1 - e^{-2} = 86,5 \%$   | 2                          | 4                 |
| 3   | $1 - e^{-4,5} = 98,9 \%$ | 3                          | 9                 |

El *pipeline* usa  $k = 3$  por defecto ( $k=3.0$  en `compute_crb_polar`). Es una región de **casi-cobertura**: si el error fuera gaussiano, el valor verdadero cae dentro en el 98,9 % de las realizaciones. No es la regla unidimensional de « $\pm 3\sigma$  cubre el 99,73 %»: en 2D hay más sitio fuera, y la misma  $k$  cubre solo el 98,9 %.

$k = 1$  es la elipse de **error típico**: semiejes  $\sigma$  a lo largo de las direcciones principales. Sirve para leer a ojo «cuánto se suele fallar».  $k = 3$  responde a otra pregunta —«dónde cae casi seguro»— y por construcción se ve tres veces más ancha y nueve veces más grande en área. **No cambia la CRB**; cambia el zoom de la curva.

### 7.3. La inclinación es la correlación

Si  $r_{\rho\varphi} = 0$ ,  $\mathbf{C}$  es diagonal, los autovectores son los ejes coordenados y la elipse sale alineada con  $(\rho, \varphi)$ . Si  $r_{\rho\varphi} \neq 0$ , giran un ángulo  $\alpha$  que cumple

$$\tan(2\alpha) = \frac{2C_{12}}{C_{11} - C_{22}}. \quad (21)$$

Con  $C_{12} < 0$  en toda la rejilla, el eje mayor apunta hacia « $\rho$  arriba,  $\varphi$  abajo»: mirar la inclinación de una burbuja es leer la dirección de compensación de la sección 6.

Los autovalores mismos mezclan metros y radianes, así que el «ángulo de inclinación» y la relación de semiejes dependen de la unidad en que se mida  $\varphi$ . No es un error: es una convención. Mientras se aplique la misma a todas las poses, las comparaciones son válidas. Lo invariante son  $\sigma_\rho$ ,  $\sigma_\varphi$  por separado, y  $\rho\sigma_\varphi$  en metros.




Figura 2: Las tres escalas sobre la misma matriz  $\mathbf{C}$  de  $(1 \text{ m}, 90^\circ)$ . La inclinación es  $r_{\rho\varphi} = -0,28$ ; el alargamiento es  $\sigma_{\text{tang}}/\sigma_\rho \approx 5$ . Pasar de  $1\sigma$  a  $3\sigma$  no «empeora» la cota: multiplica los semiejes por 3.

## 8. Cómo se dibuja (y por qué se ve arqueada)

Hay dos representaciones de  $\mathcal{E}_k$ . El *pipeline* usa la primera.

**Burbujas en el plano de parámetros.** Se toma (19) centrada en  $(\rho_0, \varphi_0)$  y se pinta sobre ejes polares con `ax.plot(phi_curve, rho_curve)`:  $\varphi$  como ángulo,  $\rho$  como radio. Es `plot_crb_regions_polar` con `use_physical_region=False`. Se elige esta vía porque **el CRB vive en el espacio de parámetros**: sus semiejes *son*  $\sigma_\rho$  y  $\sigma_\varphi$  (mezclados por la correlación). No hay transformación intermedia.

**Gotas en el plano físico  $xy$ .** La alternativa, implementada en `crb_region_physical_xy_to_polar` y apagada por defecto, transporta  $\mathbf{C}$  con la linealización

$$\mathbf{A} = \frac{\partial(x, y)}{\partial(\rho, \varphi)} = \begin{pmatrix} \cos \varphi & -\rho \sin \varphi \\ \sin \varphi & \rho \cos \varphi \end{pmatrix}, \quad \Sigma_{xy} = \mathbf{A} \mathbf{C} \mathbf{A}^\top. \quad (22)$$

Es una aproximación de primer orden: la imagen exacta de una elipse por el mapa polar→cartesiano *no* es una elipse, y al reconvertir a polares para el dibujo el contorno se curva en forma de gota. Esa asimetría no está en la CRB; está en el cambio de coordenadas. Por eso se abandonó.

El estilo polar (`_style_polar_crb_ax`) fija medio plano  $\theta \in [0^\circ, 180^\circ]$ , cero a la derecha, sentido antihorario, etiquetas radiales a dos decimales. Con `rlim=2.0` las quince poses  $\rho \in \{0,5, 1,0, 1,5\}$  m caben en el mismo marco. Eso tiene un coste de lectura: a  $3\sigma$  y  $\rho = 1,5 \text{ m}$ ,  $\sigma_\varphi$  de varios grados produce arcos que ocupan un sector enorme, mientras las de  $\rho = 0,5 \text{ m}$  quedan como puntos. No es que la CRB de cerca sea nula; es que comparte escala con la de lejos.



$3\sigma$  en  $(1\text{ m}, 90^\circ)$ : la geometría no cambia, cambia el papel




Figura 3: La misma elipse  $3\sigma$  de  $(1\text{ m}, 90^\circ)$ . Izquierda: plano cartesiano  $(\varphi, \rho)$ , donde (19) es una elipse euclídea. Derecha: los mismos puntos sobre ejes polares; un segmento de  $\rho$  constante se vuelve un arco, y la curva se ve «arqueada». No es una deformación de la cota.

CRB( $\rho, \varphi$ ) FD — regiones  $3\sigma$  — grilla  $32 \times 32$




Figura 4: Salida de `compute_crb_fd_baseline.py`: regiones  $3\sigma$  en el plano  $(\rho, \varphi)$ , grilla  $32 \times 32$ . Cada burbuja es (19) con  $k = 3$ , centrada en su pose. El aspecto «horrible» de las de  $\rho = 1,5\text{ m}$  es  $3\sigma_\varphi$  de  $22^\circ$ – $35^\circ$  dibujado como arco polar, no un fallo del trazo.

## 9. Cómo leer una burbuja

Una elipse del gráfico resume cuatro números, no uno.

1. **Anchura radial**  $\approx 2k\sigma_\rho$ : cuánto se puede fallar en rango. El tiempo de vuelo mide  $\rho$  de forma bastante directa, así que este semieje suele ser el corto.
2. **Anchura angular**  $\approx 2k\sigma_\varphi$ : cuánto se puede fallar en azimut.  $\varphi$  se infiere de la geometría de la sombra;  $\rho\sigma_\varphi$  es varias veces  $\sigma_\rho$  y el eje mayor es casi tangencial.
3. **Inclinación**: signo y magnitud de  $r_{\rho\varphi}$ . Todas las del *baseline* se inclinan en el mismo sentido porque todas las correlaciones son negativas.
4. **Radio  $k$** : si es 3, se está viendo casi-cobertura ( $\sim 99\%$  gaussiano 2D), no el error típico. Para comparar métodos a ojo,  $k = 1$  es más honesto; para citar una región de confianza,  $k = 3$  es el que usa el código.

Nada de eso es el error de un estimador que se haya corrido. Es la cota: el suelo de la covarianza de cualquier estimador insesgado de  $(\rho, \varphi)$  bajo el modelo de Poisson (3) y el *forward*  $g$  que se haya usado para construir **J**.

## 10. Mapa al código

| Función en <code>crb_polar_functions.py</code>                   | Paso de este texto                                |
|------------------------------------------------------------------|---------------------------------------------------|
| <code>forward_g_polar</code>                                     | $g = y + b$ , ecuación (2)                        |
| <code>finite_difference_jacobian_polar</code>                    | $J$ , ecuación (12)                               |
| <code>fisher_poisson</code>                                      | $I = J^T \text{diag}(1/g)J$ , ecuación (11)       |
| <code>np.linalg.pinv</code> (en <code>compute_crb_polar</code> ) | $C = I^+$ , ecuación (14)                         |
| <code>_crb_sigmas_from_matrix</code>                             | $\sigma_\rho, \sigma_\varphi, \rho\sigma_\varphi$ |
| correlación en <code>compute_crb_polar</code>                    | $r_{\rho\varphi}$ , ecuación (16)                 |
| <code>crb_region_in_polar_parameters</code>                      | elipse (19) en $(\rho, \varphi)$                  |
| <code>crb_region_physical_xy_to_polar</code>                     | empuje a $xy$ (22) (no se dibuja)                 |
| <code>plot_crb_regions_polar</code>                              | burbujas; <code>use_physical_region=False</code>  |

El *script* `compute_crb_fd_baseline.py` recorre las 15 poses  $(\rho, \varphi)$  con `estimate_height=False`,  $k = 3$  y `rlim=2.0`, y escribe `plots/crb_fd_baseline_32.png`. Las figuras de este documento se regeneran con

```
python3 docs/figs_crb_ellipses/make_figs.py
```